

PREVIZIONAREA PREȚULUI ELECTRICITĂȚII ÎN BAZA DATELOR DE ÎNCĂRCARE

Vladimir BABUSHKIN

CZU: 004.65.032.26:621.31:338.5.

vbabuschin2012@mail.ru

Accurate forecasting of electricity prices and tariffs is essential to maintain a stable interaction between supply and demand in the dynamic electricity market. The paper describes a convolutional neural network-based model for the day-ahead electricity price forecasting from historical prices/loads and predicted values of the load. The model was tested on the data for New York and New South Wales and achieved high prediction accuracy on both data sets.

Introducere. Predicția prețurilor la energia electrică reprezintă o problemă provocatoare datorită volatilității, dinamicii și structurii neomogene a datelor seriilor temporale corespunzătoare. Spre deosebire de sarcina electrică, prețul energiei electrice are o tendință mai puțin pronunțată și este puternic afectat de factorii externi: fluctuația consumului utilizatorilor finali, anotimp, condițiile meteorologice, dinamica pieței, evenimentele socioeconomice și politice etc. În plus, seriile de prețuri se caracterizează prin creșteri aleatorii. Factorii, care conduc la vârfuri, includ întreruperile de generare de energie, congestiunea transmisiei, comportamentul entităților de pe piață, manipularile pe piață și altele.

Indiferent de natura sa volatilă, *prețul energiei electrice* nu este o *variabilă aleatorie*. Ea reprezintă o structură periodică cu variații ale tendinței zilnice, corelată cu sarcina electrică, chiar dacă relația este neliniară [1].

În lucrare este descris un nou model de *rețea neuronală convoluțională* (RNC) profundă (*Convolutional Neural Network*, CNN) pentru prognozarea prețurilor la energia electrică în baza datelor privind *prețul/încărcarea istorică* și *valoarea anticipată a încărcării* din ziua următoare. RNC este capabilă să învețe tipare ascunse din datele brute, să capteze tendințe și să deducă funcții invariante la scară pentru puncte de date vecine corelate între ele. Aceste caracteristici fac ca RNC să poată fi aplicate pe scară largă pentru predicția încărcării de electricitate [2], [3]. RNC sunt, de asemenea, capabile să dezvăluie dependențe

codificate în sarcina și datele istorice ale prețurilor, care descriu fluctuațiile prețurilor. Modelarea acestor tipare ascunse oferă previziuni mai exacte ale prețului energiei electrice.

Metodologia. O primă încercare de prezicere a prețului energiei electrice prin cartografierea prețurilor și încărcarea datelor istorice cu o *rețea neuronală artificială* din două straturi ascunse a fost raportată în [4]. Spre deosebire de [4], algoritmul bazat pe RNC folosește mai puțini parametri pentru a evita suprapunerea și permite straturilor ascunse ale RNC să deducă dependențe subtile în baza datelor de intrare. RNC cu o arhitectură simplă cu mai multe straturi este capabilă să învețe mapări precise între sarcină și preț.

În baza experimentelor a fost determinat numărul de straturi de rețea optim pentru cercetare. Apoi a fost dezvoltată o RNC multistrat cu șapte straturi: (a) *trei straturi convolutive 1D (1D convolutional layers)* pentru învățarea dependențelor temporale, (b) *trei straturi de colectare (pooling layers)* intermediare și (c) *un strat dens (dense layer)* pentru procesarea datelor de ieșire ale rețelei neuronale. Primele două straturi ale RNC învață tendințele generale și zilnice în baza datelor de încărcare și prețurilor istorice. Al treilea strat este responsabil și pentru captarea altor factori externi, cum ar fi *anotimpul, întreruperile de curent și dinamica pieței*. Această arhitectură simplă multistrat este capabilă la învățarea mapărilor precise între datele de încărcare și preț. RNC obține o precizie de prognoză performantă în baza celor două seturi de date comparativ cu modelele convenționale.

Modelul RMC folosește în calitate de intrări prețurile reale pentru o zi înaintea zilei de interes P_{t-1} și o zi similară cu o săptămână în urmă P_{t-6} împreună cu încărcările reale pentru o zi înainte de ziua de interes X_{t-1} și în ziua similară de acum o săptămână X_{t-6} . Al cincilea parametru este o sarcină prevăzută pentru ziua de interes \hat{X}_t . Produsul este prețul prevăzut \hat{P}_t pentru ziua dobânzii t .

RNC a fost instruită pe date timp de un an anterior zilei t , pentru a afla dependențele dintre intrare $[P_{t-6}, P_{t-1}, X_{t-6}, X_{t-1}, \hat{X}_t]_{5 \times 24}^T$ și vectori de ieșire $[P_t]_{1 \times 24}$, unde P_t sunt valori reale ale prețului. Adăugarea mai multor date istorice cu structura *preț/încărcare* în urmă cu *două/trei/patru săptămâni* nu îmbunătățește în mod semnificativ

precizia prognozei, dar are ca rezultat un timp de calcul mai lung care ar putea provoca supraîncărcarea modelului.

Rezultate. Modelul propus a fost testat pe setul de date al prețurilor pentru operatorul de sistem independent din *New York* [5] pentru districtul *New York City* (NYC) și pentru operatorul australian de piață a energiei (AEMO) [6] pentru statul *New South Wales* (NSW) din sud-estul Australiei. Pentru instruirea modelului au fost folosite datele de încărcare și prețul pentru anul 2018. Validarea a fost efectuată pe datele anului 2019.

În Fig. 1 sunt arătate prețurile de energie electrică previzionate pentru NSW pentru luna aprilie 2019 împreună cu prețul real și valorile de încărcare.

În Fig. 2 sunt demonstrate cele mai bune și cele mai proaste prognoze din anul 2019 pentru aceeași regiune.

Concluzie. Spre deosebire de modelele convenționale, modelul bazat pe RNC convoluțională demonstrează abilitatea de descoperire a unor dependențe ascunse, cauzate de natura imprevizibilă a valorilor prețurilor și demonstrează comparativ cu modelele convenționale o performanță mai bună a prognozelor inteligente de predicție a prețurilor online și offline pentru electricitate pentru orizonturile de timp de la o singură zi la săptămâni și luni.




Fig. 1. Încărcarea și prețul previzibil /efectiv al energiei electrice pentru NSW în aprilie 2019.




Fig. 2. Cea mai bună și cea mai proastă prognoză de preț pentru New South Wales, 2019.

Referințe:

1. NEUPANE, B., WOON, W. and AUNG, Z. Ensemble Prediction Model with Expert Selection for Electricity Price Forecasting. In: *Energies*, 2017.
2. DU, S., LI, T., GONG, X., YANG, Y. and HORNG, S.-J. Traffic flow forecasting based on hybrid deep learning framework. In: *12th International Conference on Intelligent Systems and Knowledge Engineering (ISKE)*, 2017.
3. KUO, P.-H. and HUANG, C.-J. A High Precision Artificial Neural Networks Model for Short-Term Energy Load Forecasting. In: *Energies*, 2018, vol. 11, p. 213.
4. SINGHAL, D. and SWARUP, S. Electricity price forecasting using artificial neural networks. In: *International Journal of Electrical Power & Energy Systems*, 2011, vol. 33, pp. 550-555.
5. "ENERGY MARKET & OPERATIONAL DATA," New York Independent System Operator, [Online]. Available: <https://www.nyiso.com/energy-market-operational-data>. [Accessed 20.04.2020].
6. "Aggregated price and demand data," Australian Energy Market Operator, [Online]. Available: <https://www.aemo.com.au/energy-systems/electricity/national-electricity-market-nem/data-nem/aggregated-data>. [Accessed 20.04.2020].

Recunoștință dlui prof. univ., dr. ing. Gheorghe CĂPĂȚÂNĂ pentru instruire și îndrumările prețioase care au contribuit la cercetarea, pregătirea și finalizarea acestui studiu.